TFG – Elicitación conversacional de requisitos con agentes LLM en español

Oct 2, 2026 · @Geni

Resumen

Este TFG construye un agente de lenguaje que entrevista a un cliente simulado para descubrir requisitos de software en español, y un banco de pruebas propio, ReqElicit-ES, para medir cuánto descubre.

Partirás de ReqElicitGym, un entorno público en inglés que evalúa la competencia de entrevista de los LLM. Lo reproducirás, lo adaptarás al español y propondrás un entrevistador con estado estructurado que mejore su cobertura, sobre todo en los requisitos de estilo, que los modelos actuales casi no descubren.

Dedicación: 300 h en unas 15 semanas (≈ 20 h/semana). Resultado esperado: memoria, dataset con hoja de datos, código del entorno y del agente, informe de validación del simulador, resultados experimentales, demo web y paquete de réplica.

Contexto y huecos

La elicitación conversacional con LLM se ha disparado desde 2025, pero casi todo está en inglés y los modelos actuales descubren menos de la mitad de los requisitos implícitos (el mejor IRE de ReqElicitGym es 0,32). Una revisión sistemática de 2025 cubre 74 estudios de 2023-2024: predomina el prompting zero-shot y few-shot, y las técnicas interactivas y RAG apenas se exploran (Zadenoori et al.).

Trabajo	Qué hace	Dato relevante (según su resumen)
LLMREI	Chatbot entrevistador con zero-shot y least-to-most	Hasta 73,7 % de requisitos en 33 entrevistas simuladas
Elicitron	Agentes que simulan usuarios variados	Descubre necesidades latentes y diversidad de usuarios
Preguntas de seguimiento	GPT-4o genera preguntas guiado por errores típicos del entrevistador	Con guía, supera a las preguntas humanas
Generative Goal Modeling	Extrae objetivos de transcripciones con entailment	62,0 % de objetivos humanos igualados; trazabilidad 98,7 %
RECOVER	Genera requisitos a partir de conversaciones	Evalúa corrección, completitud y accionabilidad

Trabajo	Qué hace	Dato relevante (según su resumen)
LENS	Extrae requisitos explícitos y latentes de 12 entrevistas industriales	Salida como historias de usuario
ReqElicitGym	Entorno interactivo con oráculo, juez y 101 escenarios	Mejor IRE 0,32; estilo < 0,01

Huecos que aprovecha este TFG:

- Idioma: no hay banco de elicitación conversacional en español que conozcamos.
- Realismo: el oráculo de ReqElicitGym es pasivo y colaborador, y se validó con solo dos escenarios reales.
- Producto final: se mide la entrevista, no la calidad ni las invenciones de los requisitos que se redactan después.
- Estilo y parada: los modelos casi no descubren requisitos de estilo y a menudo no saben cuándo terminar.

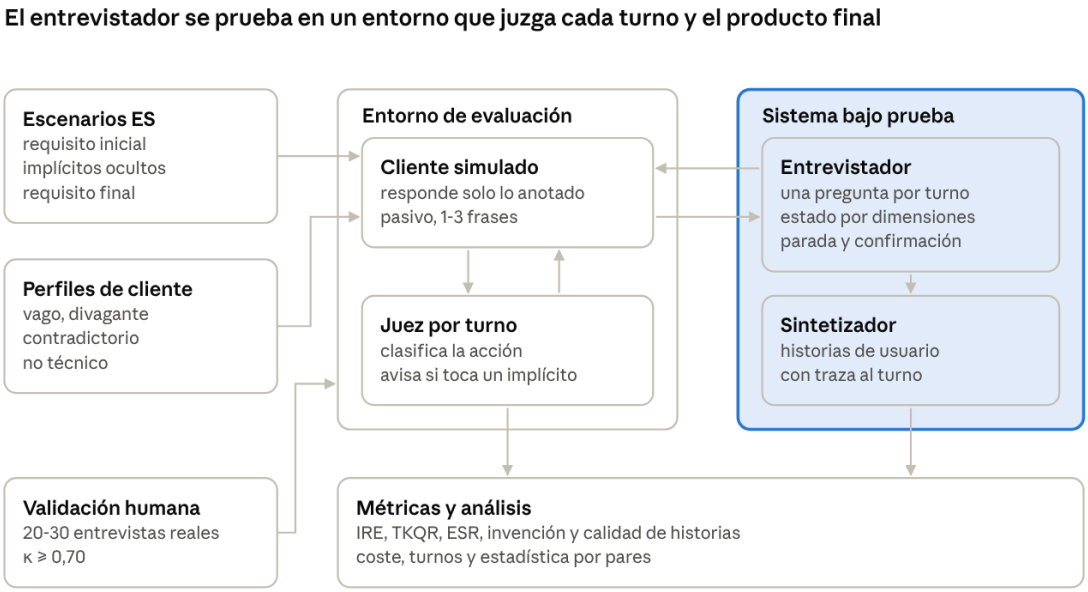
Preguntas de investigación

El TFG responde cinco preguntas; la RQ2 es la aportación principal.

RQ	Pregunta	Qué se mide / hipótesis
RQ1	¿Cuánto cambian IRE, TKQR y ESR de un entrevistador base entre el original en inglés y la versión traducida?	Mismo contenido, mismos modelos: efecto del idioma
RQ2	¿Un entrevistador con estado por dimensiones y criterio de parada supera a los baselines, sobre todo en estilo?	H2: mejora el IRE global y más en estilo, que parte de < 0,01
RQ3	¿Cómo afectan los perfiles de cliente (vago, divagante, contradictorio, no técnico) a cobertura e invenciones?	IRE e invenciones por perfil
RQ4	¿Cuánto concuerdan simulador y juez en español con anotadores humanos?	$\kappa \geq 0{,}70$ en divulgación, acción y relevancia
RQ5	¿Qué calidad tienen las historias de usuario finales y cuántas invenciones contienen?	Cobertura, precisión e invenciones frente al requisito final

Sistema final

El sistema separa el agente que se evalúa de un entorno que juzga cada turno y el documento final.



arquitectura · 8 componentes, 2 zonas

El entrevistador pregunta y el cliente simulado responde. El juez, de otra familia de modelos, clasifica cada turno y avisa al cliente si la pregunta toca un requisito pendiente. Al terminar, el sintetizador redacta historias de usuario con traza al turno de origen y las métricas las comparan con el requisito final. Las entrevistas humanas calibran cliente y juez.

Además del bucle, el sistema incluye:

- Ejecución: interfaz común para APIs y modelos locales, logs JSONL, semillas y versiones fijadas.
- Prototipo web: chat con modo «humano como cliente» y modo simulación, panel de cobertura oculto en modo humano y exportación de historias.
- Guardarraíles del entrevistador: una sola pregunta por turno y nunca pedir datos personales.

ReqElicitGym y el dataset ReqElicit-ES

ReqElicitGym es la base metodológica, pero su repositorio no incluye fichero de licencia, así que escribe a los autores en la semana 1 y mantén un plan B.

Qué es. Un entorno con tres módulos: escenarios (requisito inicial incompleto, requisitos implícitos ocultos y requisito final), un oráculo que simula al cliente y un juez que clasifica cada turno como clarificar, indagar o terminar y decide si toca un implícito pendiente. Cada sesión admite hasta 20 turnos. Métricas: IRE (cobertura de implícitos), ESR (turnos efectivos por estrategia) y TKQR (premia preguntar pronto lo importante). El repositorio usa Gymnasium y un endpoint compatible con OpenAI; los escenarios se guardan en JSON. El artículo validó el oráculo y el juez con 33 entrevistas reales (κ global de 0,73 el oráculo y de 0,73 a 0,78 el juez).

Límites que debes tener presentes

- Solo inglés y solo dominio web.
- Juez y oráculo usan el mismo modelo: hay acoplamiento y riesgo de circularidad.
- El oráculo es pasivo y colaborador.
- No se evalúan los requisitos finales redactados.
- El artículo tiene inconsistencias menores (GPT-5.1 frente a 5.2, 10 frente a 20 tipos de aplicación): fíate del código.
- Sin licencia explícita no se puede asumir permiso de reutilización ni redistribución.

Plan B si no hay permiso. Reimplementa el entorno desde el artículo y reconstruye los escenarios desde WebGen-Bench, que es MIT e incluye además 6.667 instrucciones de entrenamiento (WebGen-Instruct).

Construcción de ReqElicit-ES (vía mixta).

1. Semillas: los 101 escenarios traducidos con posedición, más 40-60 escenarios nativos (trámites, reservas, comercio pequeño, asociaciones, educación, algún caso no web).
2. Requisito final: borrador del LLM en JSON, de 8-12 historias de usuario, revisado por humanos.
3. Requisito inicial: unas 20-30 palabras que conserven la intención y omitan los detalles que habría que preguntar.
4. Implícitos por diferencia, atómicos y comprobables, con aspecto Interacción, Contenido o Estilo (se puede añadir restricciones y reglas de negocio).
5. Control de calidad en rondas hasta cero incidencias, y doble anotación del 20 % con acuerdo entre anotadores.
6. Partición dev/test, test congelado hasta el final, hoja de datos y licencia abierta compatible con las fuentes.

Perfiles de cliente. Cambian cómo responde, nunca el contenido oculto.

Perfil	Comportamiento
Colaborador	Equivale al oráculo original
Vago	Respuestas cortas e imprecisas
Divagante	Mezcla información irrelevante
Contradictorio	Cambia de opinión; el escenario lo marca
No técnico	Léxico coloquial y términos propios

Validación en español. Recoge 20-30 entrevistas humanas (por ejemplo, con roles en una asignatura de requisitos, con consentimiento informado y anonimización). Dos anotadores etiquetan cada turno y calculas κ para divulgación, acción y relevancia, más falsos positivos y negativos. Objetivo: $\kappa \geq 0{,}70$.

Paquetes de trabajo y tareas

El trabajo se reparte en 11 paquetes que suman 300 h; el núcleo imprescindible son los WP 0 a 6 y un WP 8 reducido.

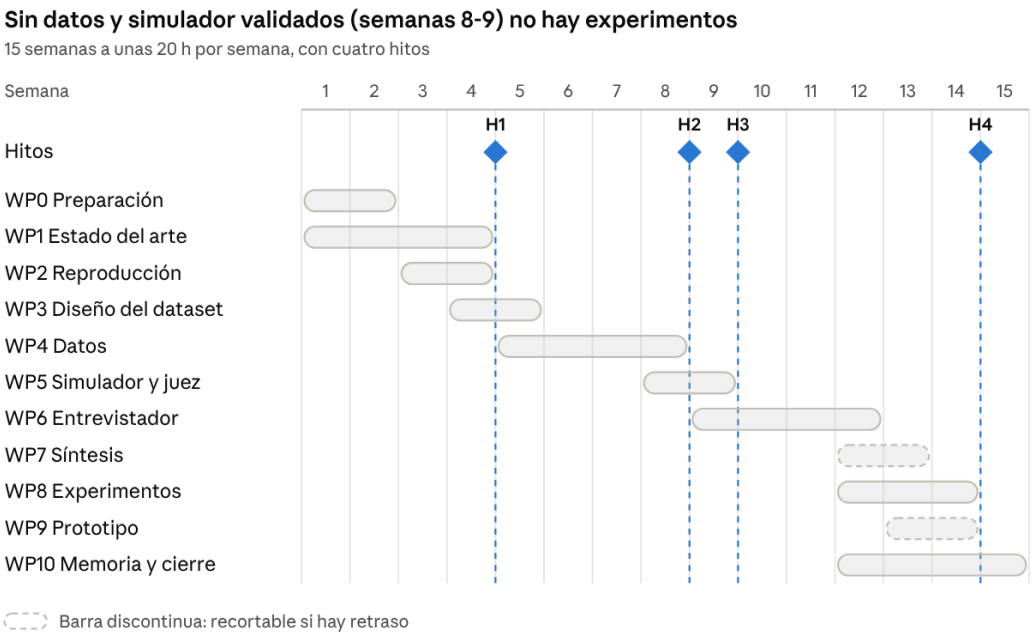
WP	Tareas	Entregable	Horas
0. Preparación	Repositorio y entorno reproducible; fijar versiones de modelos y semillas; presupuesto de API; escribir a los autores de ReqElicitBench por la licencia; revisar requisitos éticos y de datos personales	Repo, presupuesto y correo enviado	10
1. Estado del arte	Leer y tabular al menos 15 trabajos (LLMREI, Elicitron, preguntas de seguimiento, goal modeling, RECOVER, LENS, ReqElicitGym); fijar taxonomías, preguntas e hipótesis	Capítulo y matriz comparativa	25
2. Reproducción	Instalar el entorno; piloto en 10 escenarios con un modelo abierto y uno comercial; ejecución completa si el presupuesto lo permite; comparar con las cifras del artículo; medir coste por diálogo; revisar el código de juez y oráculo; documentar discrepancias	Informe de reproducción y coste	25
3. Diseño de ReqElicit-ES	Esquema JSON; taxonomía de implícitos; guía de anotación con ejemplos; selección de dominios; definición de perfiles; criterios de calidad	Guía y esquema	25

WP	Tareas	Entregable	Horas
4. Datos	Traducir los 101 con posedición de una muestra; redactar 40-60 escenarios nativos (borrador LLM y edición); tres rondas de control; doble anotación del 20 % con acuerdo; partición dev/test congelada; hoja de datos y licencia	Dataset v1	40
5. Simulador y juez	Adaptar prompts al español; separar modelos de oráculo y juez; implementar perfiles; pruebas de fuga e invención; recoger y anotar 20-30 entrevistas humanas; calcular κ, falsos positivos y negativos; ajustar y congelar	Informe de validación	25
6. Entrevistador	Baselines B0-B3; estado por dimensiones; planificador clarificar/indagar; criterio de parada; resumen y confirmación; guardarraíles; interfaz para APIs y modelos locales	Código y configuraciones de ablación	45
7. Síntesis	Generar historias de usuario con trazabilidad a turnos; evaluar frente al requisito final (cobertura, precisión, invenciones) con juez y muestra humana	Módulo y evaluación	15

WP	Tareas	Entregable	Horas
8. Experimentos	Piloto de coste; diseño reducido; ejecuciones con semillas; estadística; análisis de errores; ablaciones	Resultados y notebooks	35
9. Prototipo	Chat web con modo humano y modo simulación; panel de cobertura; exportación de historias; despliegue local	Demo	20
10. Cierre	Memoria; empaquetado de dataset, código y logs; borrador de artículo; defensa	Memoria y paquete de réplica	35

Calendario e hitos

El proyecto dura unas 15 semanas y tiene cuatro hitos; H2 y H3 (semanas 8 y 9) condicionan los experimentos.



calendario · 11 paquetes, 15 semanas, 4 hitos

H1 (semana 4): reproducción hecha. H2 (semana 8): dataset v1 y test congelado. H3 (semana 9): simulador y juez validados. H4 (semana 14): experimentos cerrados. La semana 15 queda para memoria y defensa.

Diseño experimental y métricas

Comparas seis entrevistadores sobre el mismo banco, con comparaciones pareadas por escenario y un presupuesto de unos 5.000 diálogos que ajustarás tras el piloto del WP2.

Entrevistadores

- B0: el prompt del artículo traducido, una pregunta por turno.
- B1: B0 con razonamiento en cadena.
- B2: estilo LLMREI (zero-shot y least-to-most).
- B3: preguntas guiadas por tipos de error del entrevistador, como en el trabajo de preguntas de seguimiento.
- M1: agente estructurado con estado por dimensiones (actores, flujos, contenido, reglas, restricciones, estilo, datos), planificador clarificar/indagar y criterio de parada.
- M2: M1 con resumen y confirmación al cliente.

Modelos. Al menos uno abierto con buen español y uno comercial. La familia Salamandra y ALIA-40B son abiertos con licencia Apache 2.0; el de 7B sirve como cota inferior. Comprueba en el WP0 qué memoria de GPU o qué endpoint alojado necesitas.

Diseño y volumen (estimación, a revisar tras el piloto)

- Principal: 3 modelos × 4 estrategias × unos 100 escenarios × 3 semillas ≈ 3.600 diálogos.
- Perfiles: 2 mejores estrategias × 1 modelo × 4 perfiles × 50 escenarios × 2 semillas ≈ 800 diálogos.
- Idioma: original frente a traducido, con modelos y estrategias fijos.
- Cada turno exige llamadas a entrevistador, juez y oráculo (unas 3), así que unos 10 turnos suponen unas 30 llamadas por diálogo.

Métrica	Qué mide
IRE	Proporción de requisitos implícitos descubiertos, global y por aspecto
TKQR	Descuento tipo nDCG: preguntar pronto lo importante
ESR	Proporción de turnos efectivos al clarificar y al indagar
ORA	Métrica del repositorio; revisa su definición en el código
Invención	Requisitos redactados sin base en el diálogo

Métrica	Qué mide
Redundancia y turnos	Preguntas repetidas y longitud del diálogo
Calidad de historias	Cobertura y precisión frente al requisito final
Coste	Tokens y llamadas por diálogo

Estadística. Al menos 3 semillas cuando la temperatura sea mayor que 0, intervalos bootstrap, contraste de Wilcoxon por pares y tamaños de efecto. Informa siempre coste y número de turnos junto a la cobertura.

Circularidad. Oráculo y juez de familia distinta a la de los entrevistadores evaluados; segundo juez en un 10 % de los diálogos; auditoría humana de unos 100 turnos.

Criterios de aceptación y versión mínima

El TFG se da por logrado con la reproducción documentada, un dataset congelado, un simulador validado y una mejora medida del agente estructurado.

Criterios de aceptación del mínimo viable

- Reproducción de ReqElicitGym documentada, con desviaciones explicadas y coste medido.
- Dataset ReqElicit-ES v1 con test congelado y hoja de datos.
- $\kappa \geq 0{,}70$ en divulgación, acción y relevancia para simulador y juez.
- El agente estructurado supera a B0 con intervalo de confianza que excluye cero en al menos un aspecto.
- Paquete de réplica funcional: código, dataset, logs y semillas.

Si vas con retraso, recorta en este orden

1. WP7 a una evaluación mínima.
2. WP9 a una interfaz sencilla.
3. Escenarios nativos a 30.
4. Perfiles a dos (colaborador y vago).
5. Ablaciones a dos.

Riesgos y mitigaciones

Los tres riesgos más probables son la licencia, el coste de las llamadas y un simulador poco fiable.

Riesgo	Mitigación
ReqElicitBench sin licencia	Escribir a los autores y mantener el plan B desde WebGen-Bench
Coste de API	Piloto en WP2, caché, modelos abiertos y diseño reducido

Riesgo	Mitigación
Simulador que revela de más o inventa	Pruebas de fuga e invención, política pasiva, auditoría humana
Juez erróneo o sesgado	Segundo juez en una muestra y κ frente a humanos
Novedad en un campo muy activo	Español, perfiles realistas, agente estructurado y calidad final
Contaminación de datos	Escenarios nativos nuevos y test congelado
Datos de personas	Consentimiento, anonimización y trámite ético
Modelos que cambian o se retiran	Fijar versiones, guardar logs y usar pesos abiertos como respaldo

Ética, datos y licencias

Las entrevistas con personas son la única parte que exige trámite ético y protección de datos; el resto trabaja con datos sintéticos o públicos.

- **Entrevistas humanas (WP5):** consentimiento informado, anonimización antes de almacenar, y consulta al procedimiento ético y de protección de datos de la universidad antes de recoger nada. Confirma con tu tutor qué trámite corresponde.
- **Licencias:** WebGen-Bench es MIT. ReqElicitBench no incluye licencia en el repositorio, así que no copies ni redistribuyas sus escenarios sin permiso. Elige para ReqElicit-ES una licencia abierta compatible con sus fuentes.
- **Modelos:** respeta los términos de uso de cada API y fija versiones. Los modelos Salamandra y ALIA se publican con licencia Apache 2.0.
- **Contaminación:** mantén el test de ReqElicit-ES congelado y no lo uses para ajustar prompts.

Lecturas y recursos de partida

Empieza por ReqElicitGym y LLMREI; las cifras de este documento salen de la lectura completa del artículo de ReqElicitGym y de los resúmenes del resto, así que verifica antes de citar.

- Req Elicit Gym (artículo) y repositorio ReqElicitBench
- WebGen-Bench (escenarios fuente, MIT)
- LLMREI
- Elicitron
- Requirements Elicitation Follow-Up Question Generation
- Generative Goal Modeling
- RECOVER
- LENS: requisitos latentes en conversaciones
- LLMs para ingeniería de requisitos: revisión sistemática
- NLP4RE: estudio de mapeo (Zhao et al.)

- Generador de guiones de entrevista con errores intencionados
- Experimentos de elicitación de la UPM (IEEE DataPort)
- Salamandra-7B-instruct y ALIA-40B

Entregables y evaluación

Se valorará un conjunto reproducible: memoria, datos, código, resultados y demo, no solo la memoria.

- Memoria del TFG con estado del arte, diseño, experimentos y discusión de límites.
- Dataset ReqElicit-ES v1 con guía de anotación, hoja de datos y licencia.
- Código del entorno, el simulador, el juez y el agente, con instrucciones de ejecución.
- Informe de validación del simulador y del juez (κ, falsos positivos y negativos).
- Logs, semillas y resultados de los experimentos, con los notebooks de análisis.
- Demo web con modo humano y modo simulación.
- Paquete de réplica y, si los resultados lo permiten, un borrador de artículo para un taller de ingeniería de requisitos o PLN.